

SmartHandover: Um Ensemble Multimodal para Detecção de Frustração e Encaminhamento Automático em Apoio ao Cliente

Guilherme Lobo Pinto, Pedro Alexandre Silva Gomes, Simão Novais Vieira da Silva

Mestrado em Inteligência Artificial, Departamento de Informática,
Universidade do Minho, Braga, Portugal

Avaliação de Contribuição Individual

Número	Nome	DELTA
PG60225	Guilherme Lobo Pinto	0.00
PG60289	Pedro Alexandre Silva Gomes	0.00
PG60393	Simão Novais Vieira da Silva	0.00
Somatório		0.00

Resumo A crescente dependência de agentes automatizados no apoio ao cliente evidencia um modo de falha persistente: sistemas conversacionais incapazes de reconhecer frustração e escalar a interação atempadamente. Apresenta-se o *SmartHandover*, um *ensemble* multimodal com *late fusion* que combina quatro componentes textuais (Whisper-small, VADER, j-hartmann/emotion-english-distilroberta-base e um RoBERTa-base afinado sobre o MELD com entropia cruzada ponderada) e um componente acústico (wav2vec 2.0 afinado em duas fases) sob um esquema unificado de cinco classes. As probabilidades dos cinco modelos são concatenadas num vetor de 20 dimensões e consumidas por um meta-classificador do tipo *Stacking soft-vote* (LR + XGBoost), com SMOTE no treino. Um módulo de decisão temporal aplica uma janela deslizante de três enunciados sobre $0,6 \cdot P(\text{raiva}) + 0,4 \cdot P(\text{frustração})$ e aciona o *handover* ao atravessar um limiar calibrado. Para mitigar o desbalanceamento do MELD (17,6:1), foi gerado um corpus sintético com 19 280 enunciados textuais e 9 235 amostras de áudio degradadas para banda telefónica. Sobre o teste do MELD, a configuração final atinge F1 ponderado de 0,647 e *recall* de frustração de 0,24 ao nível do enunciado, e — métrica operacionalmente mais relevante — **95,9%** de *recall* ao nível da conversa com 71,8% de *precision*. Discute-se o compromisso entre cobertura e *precision* introduzido por esta calibração (taxa de falsos disparos em conversas limpas de 58,7%) e argumenta-se, com base em três linhas de evidência independentes, que o teto de *recall* ao nível do enunciado é dominado pelo ruído do mapeamento *fear*→*frustração* no MELD — uma limitação de dados, não de modelo.

Keywords: Computação Afetiva · Reconhecimento de Emoções na Fala · Fusão Multimodal · Apoio ao Cliente · *Ensemble Learning* · Detecção de Frustração.

1 Introdução

A adoção em larga escala de *chatbots* e sistemas IVR no apoio ao cliente trouxe ganhos operacionais significativos, mas amplificou um problema antigo: os agentes automatizados não reconhecem o estado afetivo do utilizador. A frustração desencadeada por respostas irrelevantes ou tempos de espera excessivos acumula-se silenciosamente e, sem resposta empática, traduz-se em perda de clientes [18,8]. A Computação Afetiva responde a este problema com sistemas capazes de perceber emoções e, no limite, reencaminhar a chamada para um operador humano [17].

O presente trabalho desenvolve um protótipo — *SmartHandover* — que aborda a *detecção de frustração para encaminhamento automático*. A saída do sistema é uma decisão binária (*handover* / não-*handover*) calculada sobre uma pontuação contínua de emoção. Adota-se um *pipeline* multimodal que consome o áudio bruto (pistas prosódicas) e o texto transcrito (pistas lexicais). A detecção é ao nível do enunciado; a decisão de *handover* é ao nível da conversa, agregada por uma janela deslizante.

1.1 Contexto de negócio e enquadramento setorial

O setor visado é o dos *contact centers* de apoio ao cliente, em que a interação inicial é progressivamente mediada por agentes virtuais (IVR, *chatbots*, assistentes de voz). Neste contexto, o sistema dirige-se a três grupos de *stakeholders*: (i) o *cliente final*, cuja satisfação é medida por indicadores como CSAT, NPS e taxa de churn; (ii) o *operador humano*, cujo desempenho é avaliado por AHT (*Average Handle Time*) e FCR (*First Call Resolution*); e (iii) o *supervisor / gestor*, que arbitra políticas de escalada e ocupação de operadores. A literatura aplicada documenta que a detecção de emoção em chamadas é uma das aplicações de Computação Afetiva com maior tração industrial, motivada pelo custo de churn associado a interações mal resolvidas [18].

O *handover* para um humano tem custos assimétricos. Um *falso negativo* (frustração não detetada) traduz-se em risco direto de churn; um *falso positivo* (escalada desnecessária) consome tempo de operador e degrada o AHT médio. Esta assimetria justifica que se reportem métricas a dois níveis (enunciado e conversa) e que a calibração final do limiar τ seja apresentada como uma *decisão de política*, não puramente técnica (Secção 6). O *SmartHandover* é deliberadamente posicionado como um *decisor sob supervisão humana*: o sistema sinaliza, o humano valida — coerente com o quadro regulamentar europeu (RGPD, AI Act) sobre uso de dados biométricos.

A metodologia segue o CRISP-DM [26]: compreensão do problema, dos dados (MELD [20] e IEMOCAP [4] como *benchmarks*), preparação (transcrição via

ASR, unificação de *labels*, aumento sintético), modelação (classificadores unimodais, meta-classificador, módulo de decisão), avaliação (F1 ponderado, F1 macro, *recall* por classe, simulação ao nível da conversa, matriz *cross-corpus*) e reflexão sobre validade e ética. O mapeamento explícito de fases para secções do relatório encontra-se na Tabela 1.

Tabela 1: Mapeamento das fases do CRISP-DM para secções do presente relatório.

Fase CRISP-DM	Secção/conteúdo	Artefactos
Business Understanding	§1, §1.1	Definição da tarefa, KPIs
Data Understanding	§3 (corpora, distribuições)	Tabela 2
Data Preparation	§3 (mapeamento, ASR, sintético)	<code>src/data/*</code> , <code>synthetic/*</code>
Modeling	§4 (unimodais, meta, decisão)	<code>src/classifiers/*</code> , <code>decision/*</code>
Evaluation	§5 (ablação, simulação, cross-corpus)	<code>data/processed/*</code>
Deployment	§5.7 (Gradio) + §7 (governance)	<code>src/demo/app_callcenter.py</code>

Reportam-se três contribuições. Primeira, um *ensemble* multimodal ponto-a-ponto que combina um léxico, dois classificadores textuais baseados em *Transformers* e um modelo acústico sob fusão tardia. Segunda, um estudo iterativo de quatro versões do meta-classificador (v1–v4 como progressão histórica, v5 como configuração final), no qual cada intervenção — ponderação de classes, SMOTE, calibração isotónica, *stacking* — é avaliada isoladamente contra a configuração precedente. Terceira, uma simulação enunciado-a-enunciado sobre o teste do MELD que quantifica o compromisso entre falsos encaminhamentos e escaladas não detetadas. Adicionalmente, reportam-se transparentemente intervenções tentadas que *não* produziram melhoria mensurável — nomeadamente a *focal loss* [14] no *encoder* textual e a calibração probabilística do meta-classificador vencedor — contribuindo para localizar o teto de desempenho na distribuição de *labels* mais do que na arquitetura.

O restante artigo está organizado da seguinte forma. A Secção 2 revê os modelos de emoção adotados. A Secção 3 descreve os dados e o pré-processamento. A Secção 4 detalha a arquitetura. A Secção 5 apresenta os resultados, incluindo o protótipo. A Secção 6 discute limitações. A Secção 7 aborda implicações éticas. A Secção 8 conclui.

2 Fundamentação Teórica

Três famílias de modelos de emoção dominam a Computação Afetiva. O esquema *categórico* de Ekman [10] (raiva, nojo, medo, alegria, tristeza, surpresa) mapeia-se naturalmente em classificação multi-classe, mas colapsa diferenças de intensidade. O modelo *circumflexo* de Russell [23] organiza o afeto em valência $\times$ ativação, adequando-se à modelação de trajetórias — a frustração situa-se no

quadrante de elevada ativação e valência negativa. A roda de Plutchik [19] introduz *intensidade*, posicionando a frustração como estado intermédio adjacente à raiva, o que motiva o uso de limiares na política de *handover*.

O SmartHandover adota um *esquema híbrido*: categorias discretas ao nível do classificador, limiar sobre combinação convexa raiva/frustração à saída. Concretamente, todos os componentes unimodais produzem probabilidades sobre cinco classes — **raiva**, **frustração**, **tristeza**, **neutro**, **satisfação** — escolhidas para (i) preservar a distinção raiva/frustração [23], (ii) reter uma classe positiva contra encaminhamentos falsos e (iii) atenuar o desbalanceamento do MELD. O acionador opera sobre uma janela deslizante de três enunciados aplicada a $0,6 \cdot P(\text{raiva}) + 0,4 \cdot P(\text{frustração})$, com limiar calibrado em validação (Secção 4).

3 Datasets e Pré-processamento

3.1 Corpora

MELD [20]. $\approx 13\,000$ enunciados de 1 433 diálogos da série *Friends*, anotados em sete categorias (Ekman + neutro). O MELD é severamente desbalanceado: a classe minoritária mapeada para frustração contém apenas 268 exemplos em 8 783 no treino (rácio 17,6:1), motivando a estratégia de aumento sintético (Secção 3.1).

IEMOCAP [4]. $\approx 12\text{ h}$ de interações diádicas encenadas, anotadas categórica e dimensionalmente (incluindo *frustrated*). O *backbone* acústico do SmartHandover (**wav2vec2-large-superb-er**, distribuído via SPEECHBRAIN [22]) está pré-treinado para Reconhecimento de Emoções na Fala (SER, do inglês *Speech Emotion Recognition*) sobre o IEMOCAP.

CREMA-D [5]. 7 442 *clips* de 91 atores cobrindo seis emoções. Utilizado para (i) construir a matriz *cross-corpus* (Secção 5) e (ii) afinar adicionalmente o classificador acústico em conjunto com MELD e dados sintéticos.

Corpus sintético. Para mitigar o desbalanceamento e o desalinhamento de domínio (drama televisivo *vs.* *call center*), foi gerado um corpus sintético em duas vertentes assimétricas. *Vertente textual*: 21 213 enunciados produzidos com **gpt-4o-mini** sob *prompts* controlados com cenários de *call center* (faturação, falhas técnicas, atrasos) e intensidade variável, filtrados por heurísticas e por um juiz LLM independente (**mistral-small13.1** via Ollama) que validou intensidade pretendida *vs.* observada. Restaram 19 280 amostras (90,9 %) para treino. *Vertente acústica*: 9 235 amostras sintetizadas com **gpt-4o-mini-tts** sobre onze vozes com instruções de palco ([**frustrated**], [**sighing**], [**angry**]) e degradadas para banda telefónica. A vertente acústica é menor por restrições de custo de TTS; a fusão tardia absorve parcialmente esta assimetria, reportada como limitação na Secção 6.

3.2 Unificação de *labels*

Todos os corpora são mapeados sobre as cinco classes unificadas (Tabela 2). A classe *fear* do MELD é mapeada para **frustração** para aumentar o sinal disponível na classe-alvo; esta decisão constitui — como reconhecido na Secção 6 — a fonte dominante de ruído de *label* no *pipeline*, dado que a maioria dos enunciados *fear* do MELD corresponde a sobressalto cómico, não a frustração de cliente.

Tabela 2: Mapeamento das *labels* dos corpora para o esquema de cinco classes e distribuição do MELD após o mapeamento.

Classe	MELD	IEMOCAP	CREMA-D	Sintético
raiva	anger/disgust	angry	angry	anger
frustração	fear	frustrated	—	frustration
tristeza	sadness	sad	sad	sadness
neutro	neutral	neutral	neutral	neutral
satisfação	joy	happy/excited	happy	satisfaction
descartado	surprise	—	disgust, fear	—

Distribuição MELD: treino 8 783 (1 380 raiva, 268 frustração, 683 tristeza, 4 709 neutro, 1 743 satisfação); validação 958 (175/40/111/469/163); teste 2 329 (413/50/208/1 256/402). Fonte: `src/data/load_meld.py`.

A frustração corresponde a 3,1 % do treino e 2,1 % do teste — na partição de teste, cada amostra de frustração não detetada custa 2 % de *recall* absoluto.

3.3 Pré-processamento de áudio e texto

Os áudios foram reamostrados para 16 kHz, convertidos a mono e amplitude-normalizados, com redução espectral de ruído ligeira no MELD (risos, música, *crosstalk*). As amostras sintéticas foram passadas por um *pipeline* de degradação telefónica: reamostragem para 8 kHz, codificação μ -law, filtragem passa-banda 300–3400 Hz e reamostragem final para 16 kHz. Para o texto, usaram-se transcrições de referência quando disponíveis; caso contrário, *whisper-small* [21] como *front-end* ASR. O *small* foi escolhido em vez de *medium* por latência aproximadamente 2,4× inferior em GPU consumer, à custa de um WER apenas ligeiramente pior. O *tokenizer* BPE [25] do RoBERTa trunca a 128 *subword tokens* (cobre >95 % dos enunciados do MELD).

4 Metodologia

4.1 Visão geral

O sistema é um *ensemble de fusão tardia* (Figura 1). O áudio alimenta dois *pipelines* paralelos: um *caminho textual* (transcrição Whisper → três classifica-

dores textuais) e um *caminho acústico* (wav2vec 2.0 sobre o áudio bruto). Cada componente emite um vetor de probabilidades; os vetores concatenam-se num vetor de 20 dimensões consumido por um meta-classificador. Um módulo de decisão temporal agrega as probabilidades sobre uma janela deslizante e dispara o *handover*.

A fusão tardia é preferida à fusão precoce ou à atenção cruzada porque, em corpora pequenos, iguala ou supera arquiteturas mais complexas a custo menor de parâmetros [3,13], é robusta à omissão de uma modalidade e contorna o problema de alinhar *embeddings* entre componentes estruturalmente heterogêneos (léxico, *Transformers*, modelo acústico).




Figura 1: Arquitetura do SmartHandover.

4.2 Caminho de texto

VADER [12] é um analisador léxico-baseado utilizado em *zero-shot*, produzindo quatro pontuações (positiva, negativa, neutra, *compound* em $[-1, 1]$). Captura pontuação enfática, capitalização e intensificadores que os *Transformers* tendem a sub-ponderar.

Classificador Ekman+ de Hartmann [11] é o modelo `j-hartmann/emotion-english-distil-roberta-base`, utilizado em *zero-shot*. Convém esclarecer uma confusão comum: este *não* é o classificador original do trabalho GoEmotions [9] (27 classes do Reddit). É um *DistilRoBERTa-base* [24] sob um esquema Ekman+ de sete classes (*anger, disgust, fear, joy, neutral, sadness, surprise*); usamos as seis primeiras (descartando *surprise*). A escolha justifica-se pela proximidade de granularidade ao esquema de cinco classes e pela disponibilidade do *checkpoint*.¹

RoBERTa afinado no MELD. Núcleo do classificador textual: `roberta-base` [15] com cabeça de cinco classes (`src/models/text_encoder.py`). Treino mitiga o desbalanceamento por três vias: (i) `WeightedRandomSampler`; (ii) `CrossEntropyLoss` ponderada (pesos inversamente proporcionais à frequência); (iii) suplemento dos 19 280 enunciados sintéticos. *Schedule*: *freeze* de 2 épocas, *unfreeze* das 4 camadas superiores, AdamW [16], $lr = 2 \times 10^{-5}$, *gradient clipping* a 1,0, precisão mista; validação exclusivamente em MELD real.

Experiência com focal loss. Foi conduzida adicionalmente uma experiência sistemática substituindo a CE ponderada pela *focal loss* [14] com $\gamma = 2$ (`src/training/focal_loss.py`, `train_text_v5.py`). A motivação era a propriedade de concentrar gradiente em instâncias minoritárias difíceis. Empiricamente *não* produziu melhoria no *recall* de frustração em 10 épocas (Secção 5, Tabela 4). A configuração final mantém o *checkpoint* com CE ponderada; o resultado negativo é informativo e analisado na discussão.

4.3 Caminho de áudio

O classificador acústico parte de `wav2vec2-large-superb-er` [2], pré-treinado para SER sobre IEMOCAP (esquema nativo: *angry, happy, sad, neutral*). Este *checkpoint* foi afinado em duas fases (`run_dayF13_finetune_wav2vec2.py`): duas épocas com *backbone* congelado e cabeça treinável, mais cinco épocas com as quatro camadas superiores liberadas. Corpus combinado: MELD + CREMA-D + 9 235 amostras sintéticas degradadas. A cabeça final produz cinco probabilidades remapeadas para o esquema unificado; as cinco (`audio_anger, audio_frust, audio_sad, audio_neut, audio_satis`) alimentam o vetor de *features*. A segunda fase é necessária porque o *checkpoint* isolado em IEMOCAP entra em *overfit* sobre fala encenada com microfone próximo — comportamento documentado quantitativamente na Tabela 8.

4.4 Meta-classificador

As 20 saídas dos componentes — 5 RoBERTa-MELD (`prob_*`), 6 Ekman+ (`goemo_*`), 4 VADER (`vader_*`), 5 acústicas (`audio_*`) — concatenam-se num

¹ No código-fonte, as colunas correspondentes mantêm o prefixo histórico `goemo_*` por razões de retro-compatibilidade com versões anteriores do *pipeline*; designamos consistentemente o modelo no texto como “Ekman+ de Hartmann”.

vetor de 20 dimensões (`ensemble_features*_v5.csv`).² O treino é re-equilibrado com SMOTE [6] ($k = 5$). Foram testados quatro candidatos:

- **LR_balanced** — regressão logística com `class_weight="balanced"` (equivalente a v4).
- **XGB_v5** — XGBoost [7] sob grelha de 12 configurações: `n_estimators` ∈ {300, 500}, `max_depth` ∈ {4, 5, 6}, `lr` ∈ {0,05, 0,08}, com pesos por amostra.
- **MLP_balanced** — perceptron multi-camada com `class_weight="balanced"`.
- **Stacking** — média *soft-vote* das probabilidades de **LR_balanced** e do vencedor da grelha XGB [27].

A regra de seleção do v5, desenhada para equilibrar cobertura e estabilidade, é

$$\arg \max_c \frac{1}{2} \text{rec}_{\text{frust}}(c, \text{val}) + \frac{1}{2} \text{F1}_{\text{macro}}(c, \text{val}) \quad \text{s.t.} \quad \text{F1}_{\text{pond.}}(c, \text{val}) \geq 0,55.$$

A restrição inferior em F1 ponderado evita soluções que sacrificam a competência geral pela classe minoritária. Esta regra composta substitui a regra do v4 ($\arg \max \text{rec}_{\text{frust}}^{\text{val}}$ s.t. $\text{F1}_{\text{pond.}}^{\text{val}} \geq 0,55$), que tendia a selecionar candidatos com cobertura agressiva mas *precision* colapsada. A regra é aplicada sobre a validação; só após a seleção é o vencedor avaliado em teste.

4.5 Módulo de decisão

O módulo de decisão da v5 está implementado em `scripts/run_dayG5_simulate_handover_v5.py` (é esta a versão que produz todas as métricas reportadas na Secção 5); o ficheiro `src/decision/handover.py` mantém uma API de referência mais genérica, baseada em soma simples $P(\text{raiva}) + P(\text{frustração})$ na regra instantânea e massa negativa $P(\text{raiva}) + P(\text{frustração}) + P(\text{tristeza})$ na sustentada, herdada de iterações anteriores — não é a regra avaliada no presente trabalho. A fórmula efetivamente utilizada é a ponderada definida abaixo.

O módulo mantém uma janela deslizante de três enunciados sobre

$$s_t = w_a \cdot P_t(\text{raiva}) + w_f \cdot P_t(\text{frustração}), \quad w_a + w_f = 1.$$

Aplicam-se duas regras: *instantânea* (dispara se $s_t > \tau$ num único enunciado) e *sustentada* (dispara se a média de s_t sobre os três enunciados mais recentes excede $0,7 \cdot \tau$). A calibração de (w_a, w_f, τ) é feita por varrimento em grelha sobre a validação (`run_dayG4_threshold_v5.py`): $w_a \in \{0,5, \dots, 0,7\}$, $\tau \in \text{linspace}(0,10, 0,40, 16)$. Foram persistidas duas regras de seleção: **Regra A** (maximizar $\text{rec}_{\text{frust}}^{\text{val}}$ sob $\text{prec}_{\text{handover}}^{\text{val}} \geq 0,50$, herdada de v4, mantida como *fallback*) e **Regra B** (maximizar $\text{F1}_{\text{handover}}^{\text{val}}$, sem piso). A configuração final usa a Regra B: $(w_a, w_f, \tau) = (0,6, 0,4, 0,10)$.

² A versão precedente v4 utilizava 19 dimensões: o canal acústico era a saída zero-shot do SpeechBrain de 4 classes (`sb_*`). A passagem para 20-D no v5 reflete a substituição pelo wav2vec 2.0 afinado.

5 Resultados

Todos os resultados são reportados sobre o teste oficial do MELD ($n = 2329$ enunciados, 279 conversas), salvo indicação. Métricas primárias: W-F1, F1 macro, *recall* e F1 da classe frustração. A avaliação ao nível da conversa é uma simulação enunciado-a-enunciado (`run_dayG5_simulate_handover_v5.py`) que reproduz cada um dos 279 diálogos e regista se o módulo de decisão aciona o *handover*.

5.1 Baselines unimodais e ablação

A Tabela 3 consolida *baselines* unimodais (esquerda) e a ablação *leave-one-modality-out* sobre o *ensemble* v4 (direita).

Tabela 3: *Baselines* unimodais e ablação *leave-one-modality-out* sobre o teste do MELD. A ablação utiliza um meta-classificador LR sobre o subconjunto indicado de *features* do schema 19-D do v4 (canal acústico = SpeechBrain de 4 classes); a configuração final v5 substitui SpeechBrain pelo wav2vec 2.0 afinado (5 classes), totalizando 20-D. Fonte: `ablation_results.csv`, `dayF13_results.csv`.

Componente	Unimodal		Ablação (v4, 19-D)		
	W-F1	Rec. frust.	Configuração	W-F1	Rec. frust.
VADER (meta-LR, 4 <i>feat.</i>)	0,397	0,160	<i>Ensemble</i> completo	0,646	0,140
Ekman+ (meta-LR, 6 <i>feat.</i>)	0,559	0,380	– VADER	0,646	0,140
wav2vec 2.0 (argmax)	0,453	0,140	– Ekman+	0,646	0,140
RoBERTa-MELD (argmax)	0,654	0,180	– RoBERTa-MELD	0,586	0,360
			– SpeechBrain (áudio)	0,645	0,160

O RoBERTa-MELD é claramente o contribuinte dominante: a sua remoção é a única que mexe materialmente o W-F1 (−6 pp, de 0,646 para 0,586) e, em simultâneo, eleva o *recall* de frustração para 0,36 — sinal de que, sem o classificador textual afinado, o meta-classificador degenera para uma política mais agressiva sobre a classe minoritária. A remoção de VADER ou Ekman+ deixa W-F1 e *recall* essencialmente inalterados (variações sub-pontuais), evidência de redundância parcial entre os componentes textuais ponto-a-ponto. A remoção do canal acústico (SpeechBrain) é o único caso em que o *recall* de frustração sobe ligeiramente (0,140 → 0,160) sem custo apreciável no W-F1, o que sugere que o classificador acústico, treinado sobre fala encenada de *Friends*, introduz algum ruído sobre a classe-alvo neste corpus.

Sobre a contribuição (marginal) do canal acústico no MELD. Esta evidência é coerente com a observação geral de que, num domínio televisivo como o MELD,

a modalidade acústica contribui pouco para a detecção fina de frustração: as pistas prosódicas características (entoação alongada, ênfase em sílabas finais, suspiros, respiração audível) são raras em diálogo encenado de *sitcom* com som de palco e risos pré-gravados. A inclusão do canal acústico é portanto justificada *operacionalmente* (em chamadas reais a prosódia será genuína e potencialmente discriminante [8,18]), mas o seu efeito é diluído no *benchmark* disponível. A Tabela 8 (subsecção *cross-corpus*) reforça este ponto: o classificador acústico, treinado com aumento sintético, mantém competência comparável ao *checkpoint* IEMOCAP congelado quando avaliado em CREMA-D (0,537 vs. 0,536).

Confrontada com a tabela unimodal, esta análise confirma a hipótese central da arquitetura ponto-a-ponto: o sinal vem maioritariamente do texto afinado, e as restantes modalidades funcionam sobretudo como reguladores — útil para estabilidade, marginal para o *ceiling* de *recall* sobre o MELD.

5.2 Focal loss vs. entropia cruzada ponderada

A Tabela 4 compara o *checkpoint* retido (CE ponderada, herdado de v4) com o *checkpoint* re-afinado com *focal loss* $\gamma = 2$. Os dois foram treinados sobre os mesmos dados (MELD + sintético), com o mesmo *schedule* e a mesma semente.

Tabela 4: Substituição da função de perda no RoBERTa. A configuração final usa a linha **Weighted CE**. Fonte: `dayG1_summary.json`.

Função de perda	Val. rec. frust.	Test W-F1	Test F1 macro	Test rec. frust.	Test F1 frust.
Weighted CE (v4, retido)	0,15	0,654	0,487	0,18	0,195
Focal loss $\gamma = 2$ (v5)	0,15	0,649	0,479	0,14	0,144

A experiência foi interrompida pela regra de paragem definida *a priori* (limiar mínimo $\text{rec}_{\text{frust}}^{\text{val}} = 0,32$ ao fim de 10 épocas, não atingido). O *checkpoint* de *focal loss* estagnou em $\text{rec}_{\text{frust}}^{\text{val}} = 0,15$, valor idêntico ao da CE ponderada. O vetor de *features* da configuração final reutiliza, portanto, as probabilidades RoBERTa do *checkpoint* CE (registado em `dayG2_summary.json`). Este resultado negativo sugere que, no presente regime de dados, o *encoder* textual já está perto do teto imposto pela qualidade dos *labels*, e a função de perda não é a alavanca dominante.

5.3 Seleção do meta-classificador

A Tabela 5 apresenta o desempenho em teste dos quatro candidatos. A melhor configuração da grelha XGB é $n = 300$, $d = 5$, $\eta = 0,08$ (`dayG3_summary.json`). Sob a regra de seleção composta, o **Stacking soft-vote (LR + XGB)** vence em validação (score = 0,368 vs. 0,365 da LR).

Tabela 5: Candidatos de meta-classificador sobre o teste do MELD (SMOTE $k = 5$). Vencedor a negrito. Fonte: `meta_classifier_v5_summary.json`.

Candidato	W-F1	F1 macro	Recall frust.	F1 frust.
LR_balanced	0,652	0,483	0,28	0,168
XGB_v5 ($n=300$, $d=5$, $\eta=0,08$)	0,641	0,471	0,22	0,152
MLP_balanced	0,623	0,457	0,22	0,129
Stacking (LR + XGB)	0,647	0,475	0,24	0,154

O Stacking não domina os restantes em todas as métricas — a LR obtém W-F1 e *recall* marginalmente superiores em teste, mas perde em validação sob a regra composta. A escolha do Stacking reflete a hipótese de que a média de classificadores estruturalmente distintos (linear vs. ensemble de árvores) é mais estável [27]. Para o Stacking, a calibração probabilística foi omitida porque a média *soft-vote* das probabilidades já tem efeito calibrante; para os restantes candidatos, calibração isotónica e *sigmoid* foram avaliadas sobre a validação e nenhuma melhorou o macro F1 em teste. A configuração final usa Stacking sem calibração.

5.4 Comparação v5 vs. v4

A Tabela 6 apresenta a comparação direta sobre o mesmo conjunto de *features* 20-D e o mesmo teste.

Tabela 6: v4 (LR + SMOTE + isotonic) vs. v5 (Stacking soft-vote) sobre o teste do MELD. Fonte: `v5_final_summary.json`.

Métrica	v4	v5	Δ
W-F1 ponderado	0,6532	0,6471	−0,0061
F1 macro	0,4896	0,4746	−0,0150
Recall frustração	0,1600	0,2400	+0,0800
F1 frustração	0,1951	0,1538	−0,0413
Score composto $0,5 \cdot \text{rec}_f + 0,5 \cdot \text{F1}_M$	0,3248	0,3573	+0,0325

A v5 troca $\approx 1,5$ pp de F1 macro e 0,6 pp de W-F1 por um aumento absoluto de 8 pp (+50 % relativo) no *recall* de frustração. A descida do F1 da classe frustração apesar do aumento do *recall* reflete queda de *precision* na classe minoritária — comportamento esperado quando o modelo se torna mais agressivo nessa classe. Sob a regra de seleção composta, v5 é estritamente superior (+0,033 pontos).

5.5 Simulação ao nível da conversa

A Tabela 7 apresenta a métrica operacionalmente mais relevante.

Tabela 7: Simulação ao nível da conversa sobre os 279 diálogos de teste. Uma conversa é *com negativo* se contém pelo menos um enunciado raiva/frustração; *limpa* caso contrário. Fonte: `handover_simulation_v{4,5}_summary.json`.

Métrica	v4 ($\tau=0,20$)	v5 ($\tau=0,10$)
Conversas com negativo capturadas (de 170)	155	163
Conversas com negativo perdidas	15	7
Recall ao nível da conversa	0,9118	0,9588
<i>Precision</i> ao nível da conversa	0,7452	0,7181
F1 ao nível da conversa	0,820	0,821
Falsos disparos em limpas (de 109)	53	64
Taxa de falsos disparos em limpas	0,486	0,587
Latência média de captura (enunciados)	-0,76	-1,13

A v5 deteta 163 das 170 conversas com negativo (**95,9%** de *recall*, +4,7pp face a v4), capturando 8 conversas adicionais ao custo de 11 falsos disparos adicionais. A latência negativa em ambas as configurações (-0,76 em v4, -1,13 em v5) significa que o sistema dispara, em média, *antes* do enunciado anotado como negativo — comportamento pré-emptivo analisado na Secção 6. O F1 ao nível da conversa é praticamente idêntico nas duas versões ($\approx 0,82$): v5 não cria qualidade, redistribui o erro. A escolha entre v4 e v5 é, portanto, de *política* (que custo é mais aceitável) e não de *desempenho*. A esmagadora maioria dos disparos é despoletada pela regra instantânea (207 em v4, 226 em v5); apenas um disparo na totalidade da simulação resulta da regra sustentada — esperado, dado o limiar baixo ($\tau = 0,10$) e a estrutura dialogal do MELD, mas a regra sustentada mantém-se relevante para chamadas reais em que a frustração se constrói gradualmente.

5.6 Generalização *cross-corpus*

A Tabela 8 sintetiza a matriz *cross-corpus*.

Tabela 8: Matriz *cross-corpus* para texto e áudio. Colunas: conjuntos de teste. Linhas: conjuntos de treino. Fonte: `cross_corpus_matrix.csv`.

Mod.	Treino	MELD W-F1	MELD FrustR	CREMA-D	Sintético
texto	MELD apenas	0,606	0,260	—	0,466
texto	Sintético apenas	0,393	0,440	—	0,837
texto	MELD + Sintético	0,654	0,180	—	0,824
áudio	IEMOCAP congelado	—	—	0,536	—
áudio	MELD + CREMA-D	0,093	0,660	0,365	0,148
áudio	MELD + CREMA-D + Sint.	0,453	0,140	0,537	0,284

Três observações relevantes. (i) Texto **Sintético** apenas obtém 0,837 de W-F1 em teste sintético mas colapsa em MELD (0,393 W-F1; *recall* de frustração de 0,653 em sintético contra apenas 0,440 em MELD) — sinal claro de que a distribuição sintética é diferente da do MELD, justificando a decisão de combinar ambos. (ii) Áudio MELD + CREMA-D (sem sintético) apresenta W-F1 patológico em MELD (0,093) com *recall* de frustração de 0,660: o modelo prevê frustração quase universalmente; o sintético regulariza para um W-F1 utilizável. (iii) MELD + CREMA-D + **Sint.** sobre teste CREMA-D (0,537) é estatisticamente equivalente ao *checkpoint* IEMOCAP congelado (0,536), mostrando que o afinamento multi-corpus não degrada a transferência para um terceiro corpus encenado.

5.7 Protótipo Funcional

Foi desenvolvido um protótipo em *Gradio* [1] (`src/demo/app_callcenter.py`) que simula uma chamada em tempo real, permitindo a um avaliador gravar interações e observar (i) a transcrição Whisper, (ii) a evolução temporal das probabilidades de raiva e frustração e (iii) o acionamento do *handover*. As Figuras 2 e 3 ilustram um cenário de três turnos.




Figura 2: Interface da demonstração. À esquerda, gravação do cliente e resposta sintetizada do agente. À direita, transcrição cumulativa e alerta de *handover*.



Figura 3: Evolução de $0,6 \cdot P(\text{raiva}) + 0,4 \cdot P(\text{frustração})$ ao longo de três turnos. O terceiro ultrapassa o limiar do protótipo ($\tau = 0,6$, linha tracejada; mais conservador que o $\tau = 0,10$ da configuração v5 para evitar disparos em quase todas as interações no modo demonstração) e dispara o *handover*.

A demonstração materializa três propriedades: (i) a fusão tardia preserva interpretabilidade, permitindo ao supervisor humano auditar a decisão; (ii) a coexistência das regras instantânea e sustentada cobre escaladas abruptas e graduais; (iii) a separação visual cliente/agente explicita a fronteira dos dados monitorizados (relevante para a Secção 7).

6 Discussão Crítica

A interpretação dos resultados exige distinguir dois níveis de avaliação. Ao *nível do enunciado*, o *recall* de frustração da configuração final é 0,24 — modesto em termos absolutos. Ao *nível da conversa*, a mesma configuração deteta 95,9 % das chamadas com pelo menos um enunciado de frustração anotado, com deteção pré-emptiva. A aplicação alvo opera ao nível da conversa, pelo que esta segunda métrica é a operacionalmente relevante.

6.1 O teto de *recall* é uma limitação de dados, não de modelo

A evidência aponta consistentemente para uma única explicação dominante do *recall* baixo ao nível do enunciado: o mapeamento de *labels* entre *fear* do MELD e a classe-alvo **frustração** é ruidoso. A inspeção qualitativa revela que a maioria dos enunciados *fear* no MELD corresponde a sobressalto cómico (“*please don’t hurt me*”, “*oh my god, no!*”) em vez de frustração de cliente perante um serviço falhado. As duas categorias partilham valência negativa e ativação elevada, mas a frustração de cliente é uma resposta a um agente externo identificável, enquanto o sobressalto cómico é uma resposta situacional súbita.

Três linhas independentes de evidência sustentam que este é um teto de dados, não de modelo:

1. **A *focal loss* não produziu melhoria.** A intervenção arquitetural mais recomendada para desbalanceamento estagnou em $\text{rec}_{\text{frust}}^{\text{val}} = 0,15$ sem evidência de progresso (Tabela 4). Se o teto fosse imposto pela função de perda, a *focal loss* deveria ter produzido melhoria; não produziu.

2. **Os candidatos de meta-classificador saturam.** Quatro modelos estruturalmente distintos (LR, XGB, MLP, Stacking) sobre as mesmas *features* convergem para W-F1 num intervalo de ≈ 3 pp (0,623 a 0,652, Tabela 5). Esta saturação é o padrão típico quando o sinal disponível se esgota.
3. **O *cross-corpus* mostra que o *recall* se eleva quando o teste está alinhado com a distribuição.** Sintético apenas obtém $\text{rec}_{\text{frust}} = 0,653$ em sintético contra 0,440 em MELD; os classificadores aprendem frustração quando o teste está alinhado com o sentido lexical e prosódico habitual da classe.

A consequência metodológica é clara: melhorias substanciais adicionais sobre o MELD exigiriam intervenção ao nível dos *labels* (re-anotação manual da classe *fear* para distinguir sobressalto de frustração, ou recolha de chamadas reais com anotações específicas). Esta é uma limitação genuína da tarefa atual, não um defeito do *pipeline*.

6.2 O compromisso *precision–recall* ao nível da conversa

A v5 aumenta a cobertura para 95,9% mas eleva a taxa de falsos disparos sobre conversas limpas para 58,7%. Em termos absolutos é elevado, operacionalmente preocupante em produção. Três notas contextualizam: (i) “Conversa limpa” é definida nas *labels* do MELD; se a anotação do MELD perde sinal prosódico ou contextual, uma fração não negligenciável dos falsos disparos pode corresponder a deriva afetiva real não anotada — a latência negativa de $-1,13$ é consistente com esta hipótese, mas é uma hipótese, não uma conclusão. (ii) O *trade-off* é ajustável via τ : o varrimento de `dayG4_threshold_sweep_v5.csv` regista 16 valores de τ entre 0,10 e 0,40, e a passagem de $\tau = 0,10$ (v5) para $\tau = 0,20$ (configuração v4) reduz a taxa de falsos disparos de 58,7% para 48,6% à custa de 4,7 pp de *recall* ao nível da conversa — uma calibração mais conservadora ($\tau \geq 0,25$) seria preferível em produção e está documentada como decisão de política, não técnica. (iii) O F1 ao nível da conversa é praticamente idêntico em v4 e v5 ($\approx 0,82$): a v5 redistribui o erro entre falsos negativos e falsos positivos, não cria qualidade.

6.3 Modos de erro, limitações e ameaças à validade

Modos de erro. A matriz de confusão da v5 (suportada por `top_20_errors.csv`) mostra três modos dominantes: (i) confusão persistente raiva/frustração, pouco surpreendente dada a sua proximidade no plano valência-ativação; (ii) sobre-predição de neutro em enunciados curtos (< 5 *tokens*); (iii) classificação errónea de tristeza como frustração em enunciados longos do tipo queixa, parcialmente atribuível ao vocabulário do corpus sintético.

Outras limitações. **Língua:** o *pipeline* opera só em inglês; uma versão portuguesa exigiria XLM-RoBERTa, recriação do corpus sintético em PT-PT e re-avaliação. **MELD como *benchmark*:** é diálogo de série televisiva; chamadas

reais diferem em espontaneidade, codificação de *codec* e estrutura mediada por IVR. **Assimetria sintético:** cobertura textual ($\approx 19,3\text{k}$) é o dobro da acústica (9 235), introduzindo desalinhamento residual entre modalidades — a célula **sintético**→MELD fora da diagonal é a testemunha empírica. **Partição única:** o MELD é avaliado sobre teste fixo; um protocolo *leave-one-session-out* não é transferível diretamente, e os números reportados refletem estimativas pontuais (intervalos de confiança *bootstrap* seriam um próximo passo natural).

Ameaças à validade. A validade de construto é a preocupação principal: o conceito operacional de “frustração de cliente” não coincide exatamente com as *labels* do MELD nem com o *frustrated* do IEMOCAP. A validade interna é sustentada pela ablação, pela seleção sistemática do meta-classificador e pelo varrimento de limiares; a validade externa é a dimensão mais frágil — a matriz *cross-corpus* deve ser lida como limite inferior, não como evidência conclusiva de generalização.

6.4 Trabalho futuro

Os passos imediatos são: (i) recolher um pequeno corpus de chamadas reais e consentidas para ancorar a avaliação no domínio de implementação (esperando-se o maior impacto isolado); (ii) reanotar manualmente um subconjunto da classe *fear* do MELD para isolar empiricamente o teto imposto pelo ruído de *label*; (iii) estender ao português; (iv) substituir o meta-classificador por um pequeno *Transformer* sobre os *embeddings* unimodais; (v) integrar análise facial quando o canal vídeo está disponível [13].

7 Considerações Éticas

Um sistema que infere o estado afetivo de clientes em interações comerciais coloca preocupações éticas que extravasam a habitual lista de verificação de equidade em ML.

Privacidade e consentimento. Voz e emoção são categorias especiais de dados pessoais ao abrigo do RGPD. Qualquer implementação em produção exige consentimento explícito, informado e revogável no início de cada chamada, com declaração clara do propósito, período de retenção e destinatários. Deve observar-se minimização: o áudio bruto não deve ser armazenado para além da janela de inferência, e o estado inferido deve ser retido apenas durante o tempo estritamente necessário à decisão. Os registos de auditoria devem registar decisões, não trajetórias emocionais em bruto.

Viés e representatividade. Os dados de treino são dominados por atores de inglês americano (MELD, IEMOCAP). Isto enviesará os modelos em direção a uma demografia restrita e pode degradar o desempenho — ou, mais preocupantemente, classificar sistematicamente de forma errónea — para falantes com sotaques não

nativos, dialetos regionais ou deficiências da fala. O corpus sintético, gerado por LLM, herda os vieses dos seus próprios dados de treino. Uma implementação responsável requer reporte de desempenho por subgrupo (gênero, faixa etária, sotaque) e um orçamento de erro explícito por subgrupo.

Assimetria de poder e utilização indevida. Um sistema de *handover* é, por desenho, um sistema de monitorização em tempo real. Decorrem dois riscos concretos: (i) repropósito para classificar agentes em vez de clientes, com implicações em direitos laborais; (ii) extensão para conduzir políticas de preços ou retenção, constituindo transição da *adaptação afetiva* para a *exploração afetiva*. A política de utilização deve excluir explicitamente tais usos.

Transparência e direito a um humano. O propósito declarado — escalar para um humano — reforça transparência: o resultado visível é uma pessoa. O caso inverso (o sistema infere não-frustração e *não* escala) é a escolha de política que os clientes devem poder anular: um comando “transfira-me para um humano” tem de permanecer disponível incondicionalmente.

Custos assimétricos. A escolha do limiar τ é uma decisão ética: um τ mais alto reduz encaminhamentos falsos (custosos para o operador) mas aumenta escaladas não detetadas (custosas para o cliente). O ponto de operação reportado ($\tau = 0,10$) é deliberadamente agressivo em *recall* e tem de ser explicitamente justificado em qualquer implementação real, em diálogo com partes interessadas em proteção do consumidor.

Chilling effect. A consciência de estar sob monitorização emocional pode alterar o comportamento expressivo natural, reforçando a obrigação de transparência e desaconselhando o uso encoberto em contextos com alternativas comerciais limitadas para o cliente.

Alinhamento com os Objetivos de Desenvolvimento Sustentável (ODS). A Agenda 2030 das Nações Unidas estabelece 17 ODS que servem de referencial para avaliar o impacto societal de soluções tecnológicas. O SmartHandover, enquanto sistema de Computação Afetiva aplicado ao apoio ao cliente, relaciona-se de forma substantiva com três objetivos:

- **ODS 8 — Trabalho Digno e Crescimento Económico.** Os *contact centers* são um setor com índices reconhecidamente elevados de *burnout*, exaustão emocional e rotatividade de operadores. Ao filtrar e encaminhar atempadamente chamadas de maior intensidade emocional, o SmartHandover pode contribuir para uma distribuição mais sustentável da carga emocional, reduzindo a exposição prolongada de operadores a interações hostis e melhorando a qualidade do ambiente de trabalho. A ressalva ética discutida acima (risco de repropósito para monitorização de agentes) deve ser explicitamente excluída para que esta contribuição se concretize.

- **ODS 9 — Indústria, Inovação e Infraestruturas.** O projeto demonstra aplicação responsável de técnicas avançadas de IA (*Transformers*, fusão multimodal, aumento sintético) num processo industrial maduro, com *governance* explícita, auditabilidade da decisão e *pipeline* reproduzível. Contribui assim para uma infraestrutura digital mais inteligente e resiliente em serviços de apoio mediado.
- **ODS 10 — Reduzir as Desigualdades.** Um sistema eficaz de *handover* pode democratizar o acesso a apoio humano de qualidade, evitando que clientes mais vulneráveis (idosos, pessoas com menor literacia digital, falantes não nativos) fiquem retidos em ciclos de IVR ineficazes. Esta contribuição depende, contudo, criticamente da mitigação dos vieses demográficos discutidos nesta secção: sem reporte de desempenho por subgrupo, o sistema pode *aprofundar* desigualdades em vez de as reduzir.

De forma secundária, o projeto toca ainda no **ODS 16** (Instituições eficazes e responsáveis) pela ênfase em transparência, direito a recurso a um humano e auditabilidade da decisão. A nossa abordagem é deliberadamente cautelosa: a contribuição para os ODS não é apresentada como benefício automático da tecnologia, mas como um resultado condicionado à implementação responsável das salvaguardas descritas nesta secção.

8 Conclusão

Apresentou-se o *SmartHandover*, um protótipo ponto-a-ponto para deteção automática de frustração em apoio ao cliente mediado por voz. O sistema combina quatro componentes textuais (Whisper-small, VADER, Ekman+ de Hartmann e RoBERTa-base afinado com CE ponderada) com um classificador acústico (wav2vec 2.0 afinado em duas fases), sob um meta-classificador Stacking *soft-vote* sobre vetor 20-D. Um corpus sintético com $\approx 19,3$ k textos (dos quais 9,2k acusticamente sintetizados e degradados para banda telefónica) compensa o desbalanceamento severo do MELD.

Sobre o teste do MELD, a configuração final atinge $W-F1 = 0,647$ e $F1_{\text{macro}} = 0,475$ ao nível do enunciado, com *recall* de frustração elevado de 0,16 (v4) para 0,24. A métrica operacionalmente relevante é, contudo, ao nível da conversa: **95,9%** de *recall*, 71,8% de *precision*, 58,7% de falsos disparos em conversas limpas, -1,13 enunciados de latência média (pré-emptiva). A demonstração em *Radio* materializa o comportamento em tempo real e torna a decisão auditável.

A principal lição metodológica é que, para tarefas afetivas com classes desbalanceadas, o teto de desempenho pode estar na *qualidade dos labels* mais do que na arquitetura ou na função de perda. As experiências negativas reportadas — *focal loss* e calibração do meta-classificador — não produziram melhoria, e essa ausência é informativa: confirma, em conjunto com a saturação entre candidatos e com o *cross-corpus*, que o mapeamento *fear*→*frustração* no MELD constitui o constrangimento dominante. A principal lição ética é que um sistema de *handover* consciente de emoção é inevitavelmente um sistema de monitorização em tempo real, e a sua implementação responsável exige consentimento explícito,

responsabilização por subgrupo, política contra exploração afetiva ...e direito incondicional do cliente a um operador humano a pedido. Sob estas condições, o sistema alinha-se com os Objetivos de Desenvolvimento Sustentável 8 (trabalho digno), 9 (inovação responsável) e 10 (redução de desigualdades) discutidos na Secção 7.

Glossário de Abreviações

AHT	<i>Average Handle Time</i> — tempo médio de atendimento.
AI Act	<i>Artificial Intelligence Act</i> — regulamento europeu sobre sistemas de IA.
ASR	<i>Automatic Speech Recognition</i> — reconhecimento automático de fala.
BERT	<i>Bidirectional Encoder Representations from Transformers</i> .
BPE	<i>Byte-Pair Encoding</i> — algoritmo de tokenização em subwords.
CE	<i>Cross-Entropy</i> — entropia cruzada (função de perda).
CREMA-D	<i>Crowd-sourced Emotional Multimodal Actors Dataset</i> .
CRISP-DM	<i>Cross-Industry Standard Process for Data Mining</i> .
CSAT	<i>Customer Satisfaction Score</i> .
DL	<i>Deep Learning</i> — aprendizagem profunda.
ERC	<i>Emotion Recognition in Conversations</i> .
F1	Média harmónica entre <i>precision</i> e <i>recall</i> .
FCR	<i>First Call Resolution</i> — taxa de resolução à primeira chamada.
GPU	<i>Graphics Processing Unit</i> .
IEMOCAP	<i>Interactive Emotional Dyadic Motion Capture</i> (corpus).
IVR	<i>Interactive Voice Response</i> — sistemas de resposta vocal interativa.
KPI	<i>Key Performance Indicator</i> — indicador-chave de desempenho.
LLM	<i>Large Language Model</i> — modelo de linguagem de grande escala.
LR	<i>Logistic Regression</i> — regressão logística.
MELD	<i>Multimodal EmotionLines Dataset</i> .
ML	<i>Machine Learning</i> — aprendizagem automática.
MLP	<i>Multi-Layer Perceptron</i> — perceptrão multi-camada.
NPS	<i>Net Promoter Score</i> .
ODS	Objetivos de Desenvolvimento Sustentável (Agenda 2030, ONU).
RGPD	Regulamento Geral de Proteção de Dados (UE).
RoBERTa	<i>Robustly Optimized BERT Pretraining Approach</i> .
SER	<i>Speech Emotion Recognition</i> — reconhecimento de emoções na fala.
SMOTE	<i>Synthetic Minority Over-sampling Technique</i> .
TTS	<i>Text-to-Speech</i> — síntese de voz.
VADER	<i>Valence Aware Dictionary and sEntiment Reasoner</i> .
W-F1	<i>Weighted F1</i> — F1 ponderado pela prevalência de cada classe.
WER	<i>Word Error Rate</i> — taxa de erro por palavra.
XGBoost	<i>eXtreme Gradient Boosting</i> .
μ-law	Algoritmo de quantização logarítmica de áudio (codec telefónico).

Referências

1. Abid, A., et al.: Gradio: Hassle-free sharing and testing of ML models in the wild. In: arXiv:1906.02569 (2019)
2. Baevski, A., Zhou, H., Mohamed, A., Auli, M.: wav2vec 2.0: A framework for self-supervised learning of speech representations. In: NeurIPS (2020)
3. Baltrušaitis, T., Ahuja, C., Morency, L.P.: Multimodal machine learning: A survey and taxonomy. *IEEE TPAMI* **41**(2), 423–443 (2018)
4. Busso, C., et al.: IEMOCAP: Interactive emotional dyadic motion capture database. *Language Resources and Evaluation* **42**(4), 335–359 (2008)
5. Cao, H., et al.: CREMA-D: Crowd-sourced emotional multimodal actors dataset. *IEEE Trans. Affective Computing* **5**, 377–390 (2014)
6. Chawla, N.V., et al.: SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research* **16**, 321–357 (2002)
7. Chen, T., Guestrin, C.: XGBoost: A scalable tree boosting system. In: KDD. pp. 785–794 (2016)
8. Cowie, R., et al.: Emotion recognition in human-computer interaction. *IEEE Signal Processing Magazine* **18**(1), 32–80 (2001)
9. Demszky, D., et al.: GoEmotions: A dataset of fine-grained emotions. In: ACL. pp. 4040–4054 (2020)
10. Ekman, P.: An argument for basic emotions. *Cognition and Emotion* **6**(3–4), 169–200 (1992)
11. Hartmann, J.: Emotion English DistilRoBERTa-base. <https://huggingface.co/j-hartmann/emotion-english-distilroberta-base> (2022)
12. Hutto, C.J., Gilbert, E.: VADER: A parsimonious rule-based model for sentiment analysis of social media text. In: ICWSM. pp. 216–225 (2014)
13. Lian, H., et al.: A survey of deep learning-based multimodal emotion recognition. *Entropy* **25**(10), 1440 (2023)
14. Lin, T.Y., Goyal, P., Girshick, R., He, K., Dollár, P.: Focal loss for dense object detection. In: ICCV. pp. 2980–2988 (2017)
15. Liu, Y., et al.: RoBERTa: A robustly optimized BERT pretraining approach. arXiv:1907.11692 (2019)
16. Loshchilov, I., Hutter, F.: Decoupled weight decay regularization. In: ICLR (2019)
17. Picard, R.W.: *Affective Computing*. MIT Press (1997)
18. Plaza, M., et al.: Emotion recognition method for call/contact centre systems. *Applied Sciences* **12**(21), 10951 (2022)
19. Plutchik, R.: The nature of emotions. *American Scientist* **89**, 344–350 (2001)
20. Poria, S., Hazarika, D., Majumder, N., Naik, G., Cambria, E., Mihalcea, R.: MELD: A multimodal multi-party dataset for emotion recognition in conversations. In: ACL. pp. 527–536 (2019)
21. Radford, A., et al.: Robust speech recognition via large-scale weak supervision. In: ICML (2023)
22. Ravanelli, M., et al.: SpeechBrain: A general-purpose speech toolkit. arXiv:2106.04624 (2021)
23. Russell, J.A.: A circumplex model of affect. *Journal of Personality and Social Psychology* **39**(6), 1161–1178 (1980)
24. Sanh, V., Debut, L., Chaumond, J., Wolf, T.: DistilBERT, a distilled version of BERT: Smaller, faster, cheaper and lighter. arXiv:1910.01108 (2019)
25. Sennrich, R., Haddow, B., Birch, A.: Neural machine translation of rare words with subword units. In: ACL. pp. 1715–1725 (2016)

26. Wirth, R., Hipp, J.: CRISP-DM: Towards a standard process model for data mining. In: PKDD. pp. 29–39 (2000)
27. Wolpert, D.H.: Stacked generalization. *Neural Networks* **5**(2), 241–259 (1992)